

东北林业大学

毕 业 论 文

基于深度学习的小麦病害分类 模型特征分析

学生姓名:	马群
专业班级:	信息与计算科学 2015 级 1 班
指导教师:	史春妹 讲师
学 院:	理学院

2019 年 6 月

基于深度学习的小麦病害分类模型分析

摘要

为了实时监控小麦病害情况并及时采取防治措施，本文构建了一个适合处理小麦常见病害的卷积网络分类模型。本文以小麦病害图片为基础，经过挑选、裁剪、图像矩阵序列化等操作获得标准数据集，通过构建多个深度神经网络模型进行对比，并使用随机梯度下降法对模型权重进行学习。在此基础上改进表现较差的神经网络模型，以说明本文卷积网络的处理能力。实验结果表明，本文提出的卷积神经网络模型在小麦病害分类问题上表现良好，验证准确率在（Validation Accuracy）93% 左右。在和经典卷积模型 LeNet-5 对比实验后发现，本文模型准确率高于 LeNet-5（84%）。这表明使用卷积神经网络进行小麦常见病害的识别是有效且可行的，理论上为小麦病害的实时分析提供了有效且强力的分析手段。

关键词 深度学习；卷积神经网络；图像识别；模型分析；小麦病害

Feature analysis of wheat disease classification model based on deep learning

Abstract

In order to monitor the disease situation of wheat in real time and take preventive measures in time, a convolutional network classification model suitable for dealing with common diseases of wheat was constructed in this paper. Based on the pictures of wheat diseases, this paper obtains standard datasets through selection, cropping, image matrix serialization, etc., constructs multiple deep neural network models for comparison, and uses stochastic gradient descent method to learn model weights. On this basis, the poor performance neural network model is improved to illustrate the processing power of the convolutional network. The experimental results show that the proposed convolutional neural network model performs well on the classification of wheat diseases, and the verification accuracy rate is about 93% (Validation Accuracy). After comparing with the classical convolution model LeNet-5, the accuracy of the model is higher than that of LeNet-5 (84%). This indicates that the use of convolutional neural networks for the identification of common wheat diseases is effective and feasible, and theoretically provides an effective and powerful analytical tool for real-time analysis of wheat diseases.

Keywords Deep Learning; CNN; Image Identification; Characteristics; Wheat Disease

目录

摘要

Abstract

1 前言.....	1
1.1 研究背景及意义	1
1.2 农作物病害识别的国内外研究现状	1
1.2.1 国内研究现状	1
1.2.2 国外研究现状	2
1.3 深度学习与神经网络的发展	2
1.4 论文结构和研究内容	3
1.4.1 主要研究内容	3
1.4.2 论文结构	3
2 卷积网络.....	5
2.1 卷积	5
2.2 卷积网络简介	6
2.3 卷积网络的特点	6
2.4 卷积网络的结构	7
3 基于卷积网络的小麦病害图像分类.....	8
3.1 本文卷积网络结构	8
3.2 LeNet-5 和 AlexNet 结构简介	10
3.3 实验步骤及操作	11
3.3.1 数据的获取及处理	11
3.3.2 卷积网络模型的建立	12
4 实验结果分析.....	14
4.1 初步实验	14
4.2 参数优化与模型对比	14
4.3 模型性能对比	15
4.4 分布图与直方图	16
结论.....	18
参考文献.....	19
致谢.....	20

1 前言

1.1 研究背景及意义

小麦是我国三大粮食作物之一，其种植区域主要分布在长江以北的大部分地区，种植面积位居第二，仅次于水稻。病害是影响小麦等农作物产量和质量的首要问题。全世界范围内小麦病害大约有 200 多种，每年造成的产量损失约为 15%~20%^[1]。在我国危害较严重的有三十多种，其中以白粉病（Wheat powdery mildew）、锈病（*Puccinia striiformis* West, 包括条锈、秆锈、叶锈）、叶枯病（Wheat leaf blotch）、赤霉病等在我国主要小麦产地分布较广，为害较为严重。

传统形式的小麦病虫害是依靠经验识别、人工喷施农药进行防治的。在大面积的小麦种植模式下，人工防治不仅需要大量的人力物力，而且在喷施农药的过程中极为不安全。更进一步地讲，即使是在技术人员的帮助下进行病害防治，也不能做到实时监控小麦病害情况、及时实施防治工作。因此如何做到实时监控并报告小麦病害情况成为了现代农业生产中的重要目标。

自 1980 年机器学习被称为一个独立的方向开始，经过一代又一代人的努力，诞生了大量经典的分类算法。其中以朴素贝叶斯（Naive Bayes, NB）、K-均值聚类（k-means clustering）、逻辑回归（Logistic Regression, LR）、决策树（Decision Tree, DT）、支持向量机（Support Vector Machine, SVM）等浅层机器学习模型最为常用，它们的出现为小麦病害的自动识别提供了有力的理论支持。但是这些经典分类算法的图像特征提取策略是基于先验知识制定的，效率不高且不适合应用在大规模特征提取方面^[2]。近年来，由 AlphaGo 带来的人工智能热潮使得深度学习一词出现在公共视野里。深度学习是机器学习领域中一种以人工神经网络为架构，通过数据进行表征学习的算法。

如此一来，将现代的深度学习技术与传统图像处理相结合的方式成为了农作物病害识别的新手段。深度学习在图像处理领域的优势不仅仅在于能够准确地提取特征，还在于它通过处理大量图像数据时能不断地自我学习并取得更高的准确率。

在以深度学习为主要手段的图像处理过程中，卷积神经网络模型对图像的处理由很高的优势，故本文研究的内容会以卷积神经网络为基础，通过建立不同结构的神经网络模型并加以比较，找出最适合小麦病害识别的深度网络模型。

1.2 农作物病害识别的国内外研究现状

1.2.1 国内研究现状

国内在农作物病害识别方面的研究起步较晚，多数是在国外相关研究启发下开始的。近年来机器学习领域的研究呈现井喷式发展，随之带动了农作物病害识别的研究，并取得了许多卓有成效的识别技术。2009 年，王守志等实现了基于核 K-均值聚类方法的玉米叶

部病害识别,实验涉及的4种玉米病害识别准确率达82.5%^[3];2011年,陈丽等提出了一种基于图像处理技术和概率神经网络技术的玉米叶部病害识别方法,利用遗传算法优化选择出4个分类能力强的分类特征,由概率网络(PNN)分类器识别病害,平均准确率为90.4%,高于BP神经网络^[4];2012年,王树文等利用基本图像处理方法对黄瓜叶部病害图像进行处理,综合运用二次分割、形态学滤波得到病斑区域。提取三种特征并采用BP算法训练多层前向神经网络对黄瓜病害进行分类,该系统的平均识别准确率为95.31%^[5];2013年,张飞云等利用量子神经网络进行玉米病害分类识别,对玉米灰斑病、玉米普通锈病和玉米小斑病的识别准确率达92.5%、97.5%和92.5%,高于误差反向传播神经网络的识别率(分别为90.0%、90.0%和92.5%),可用于玉米叶部病害识别^[6]。

1.2.2 国外研究现状

国外关于农作物病害识别的研究起步较早,在上世纪九十年代已有多种识别方法被提出。在早期的处理方法大多是对病害图像进行前期处理,包括图像分割、滤波、简单分类等技术,或是辅助以人工分析,然后再结合农作物病理学知识对处理后的数据进行分类识别。1997年,Tucker与Chakraborty提供了一种专用软件,可以检测向日葵和燕麦叶片上的病变,提供病变数量和类型以及病害严重程度的数据,但是该软件的分类准确率达不到预想程度^[7];1999年,Sasaki等使用光谱反射特性和滤光片图像构建了一个植物病害自动诊断系统,发现500、600和650nm的滤光镜图像比其他滤光镜图像更适合于识别,在创建鉴别参数对健康叶片和患病叶片进行分类后,达到了5%或更小的误差率^[8]。

由于图像处理技术的限制,早期的农作物病害识别技术并不能满足人们的要求。近年来,随着图像处理和人工智能的发展,机器学习应用到农作物病害识别领域的例子越来越多。2008年,Phadikar和Sil等介绍了一种基于水稻植株感染图像的水稻病害检测系统,该系统使用图像生长、分割技术处理感染部分,然后使用SOM神经网络将四种叶子的感染部分进行分类处理,实验结果令人满意^[9];2014年,Mathura与Uttar Pradesh介绍了一种基于邻近像素点像素强度的改进和差直方图,与梯度滤波器相配合使用可以对苹果病害的检测达到99%的准确率^[10];2016年,Sladojevic等实现了最新一代的卷积神经网络(CNN),该模型能够识别健康叶片中的13种不同类型的植物病害,实验结果的平均精确度达到了96.3%^[11];2017年,Fuentes和Yoon等提出了一种深度学习方法来检测番茄病害,该方法含有三种神经元架构:基于区域的快速卷积网络(Faster R-CNN)、基于区域的全卷积网络(R-FCN)和单发多核检测器(SSD),实验结果表明,该系统能有效识别九种不同类型的病虫害^[12]。

1.3 深度学习与神经网络的发展

深度学习是机器学习领域中一种以人工神经网络为架构,根据数据进行表征学习的算法。它的前身是人工神经网络,基本特点是模仿人脑神经元处理和传递信息的方式,本质是解决贡献度的分配问题。

对深度学习的研究最早可以追溯到 1943 年，数学家皮兹（W.Pitts）和神经科学家麦卡洛克（W.S.McCulloch）建立了一个基于神经网络和数学的模型，称为 MCP 模型。该模型是按照人脑神经元的结构和工作原理构造出来的一个抽象的、简化了的模型，也被人们称为“模拟大脑”^[13]。1958 年，计算机科学家罗森布拉特（Rosenblatt）提出了感知器（Perceptrons），这是一个由两层神经元组成的神经网络。这也是第一次将 MCP 模型用于机器学习分类。“感知器”算法使用 MCP 模型对输入的多个维度数据分为两类，且能够在训练过程中自动优化并更新权值。1962 年，Novikoff 定理证明该方法具有收敛性，理论与实践效果引起第一次神经网络热潮。

神经网络之父 Geoffery Hinton 于 1986 年发明了适用于多层感知器（MLP）的 BP（Backpropagation）算法，该方法采用 Sigmoid 进行非线性映射，有效解决了非线性分类和学习的问题。Sigmoid 函数的输出在 (0,1) 内，单调连续且易于求导，非常适合用作输出层。但是它也有软饱和性的缺点，一旦落入饱和区， $f'(x)$ 就会变得接近于 0，很容易产生梯度消失。90 年代中期，支持向量机（Support Vector Machine, SVM）算法诞生，随之各种浅层机器学习模型被提出。支持向量机又名支持向量网络，是在分类与回归分析中分析数据的监督式学习模型与相关的学习算法^[14]。支持向量机与其他浅层机器学习算法的提出再次使深度学习的发展受到阻碍。

Hinton 所带领的课题组为了测试深度学习模型的能力，于 2012 年使用首次使用 CNN 网络 AlexNet 参加 ImageNet 图像识别比赛，在 ImageNet 评测上将错误率从 26% 降低到 15%，在第二名（SVM 方法）面前以压倒性的优势夺得冠军。

深度学习虽然已经成为众多科研领域的热门研究内容，但是目前还处于发展阶段，不管是理论方面还是实践方面都还有许多问题待解决，不过由于我们处在了一个“大数据”时代，以及计算机处理能力的大大提升，新理论的验证周期会大大缩短，人工智能的发展必然会很大程度地改变这个世界。

1.4 论文结构和研究内容

1.4.1 主要研究内容

本文以提高卷积网络在小麦病害图像识别的准确率为目标，提出了具有 12 层结构的卷积网络。针对前期实验的不足之处对网络结构加以更改，在得到了训练过程中表现良好的网络模型的模型之后，将其与经典卷积网络模型 LeNet-5、AlexNet 的实验结果进行比较，分析本文模型的长处与不足，验证该模型在小麦病害图像识别中的有效性。

1.4.2 论文结构

第一章是引言，首先介绍了小麦病害图像识别的研究背景和意义，然后综述了深度学习与神经网络的发展历史及研究现状，最后介绍了本文的主要研究内容和章节安排。

第二章主要介绍了卷积的基础理论知识，然后简单介绍了卷积神经网络的发展及其特点和主要结构层次。

第三章搭建了一个结构上较新颖的卷积神经网络模型，并针对小麦病害识别加以修改，使其尽量符合预期要求。接下来主要介绍了实验内容，首先是数据源的获取和处理，然后是不同模型在相同数据源下的训练过程。

第四章是针对该实验结果的分析以及对不同模型的结果加以对比，说明本文新模型的优势。然后对数据集的质量进行了解释，以及数据集对训练结果的影响。最后是对本文的总结分析。

2 卷积网络

2.1 卷积

卷积（Convolution）是分析数学中的一种积分变换的方法，是其中一个函数反转并平移后与另一个函数乘积的积分。设 f 与 g 是 \mathbf{R}_1 上的两个可积函数，做积分后的新函数就成为函数 f 与 g 的卷积：

$$f * g = \int_{\tau \in A} f(\tau)g(t - \tau)d\tau$$

卷积也经常应用在图像处理中，因为图像是一个二维结构，所以适合用二维卷积对图像做特征提取等操作。给定一个图像 $\mathbf{I} \in \mathbb{R}^{M \times N}$ ，和滤波器 $\mathbf{K} \in \mathbb{R}^{M \times N}$ ，一般 $m \ll M$ ， $n \ll N$ ，其卷积为：

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n)K(i - m, j - n) \quad (2-1)$$

下式为二维卷积示例：

$$\begin{pmatrix} 2 & 0 & 1 & 1 & 1 \\ -1 & 0 & -3 & 0 & 1 \\ 2 & 1 & 1 & -1 & 0 \\ 0 & -1 & 1 & 2 & 1 \\ 1 & 2 & 1 & 1 & 1 \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & -1 \end{pmatrix} = \begin{pmatrix} -1 & 1 & -1 \\ 2 & 2 & 4 \\ -1 & 0 & 0 \end{pmatrix} \quad (2-2)$$

卷积是可交换的，我们可以等价地把 (2-1) 式写作：

$$(2-1) \Leftrightarrow S(i, j) = (K * I)(i, j) = \sum_m \sum_n I(i - m, j - n)K(m, n) \quad (2-3)$$

(2-3) 式也被称为 I 和 K 的互相关（Cross-Correlation），它是一个衡量两个序列相关性的函数。通过 (2-1)、(2-3) 两式对比可知，卷积和互相关的区别仅仅在于卷积核是否进行了翻转（Flip）。许多机器学习库中实现的“卷积运算”其实是互相关函数，之所以称之为卷积运算，这是因为卷积核的特征提取能力与其是否翻转无关。在训练过程中，学习算法会在核合适的位置自动更新为恰当的值，所以一个基于互相关学习算法所学习到的核，是使用卷积运算所学到的核的翻转。

数字图像是二维图像用有限数字数字像素的表示^[15]，对数字图像做卷积操作其实是在图像上滑动一个卷积核（即滤波器），将图像点上的像素值与卷积核对应位置的值相乘，然后将相乘后所有的值相加，作为特征图像上对应位置的像素值。图 2-1 展示了式 (2-2) 中反转前后的卷积核在小麦锈病图像中特征提取效果的对比图。




图 2-1 卷积核的翻转对特征提取的影响

2.2 卷积网络简介

卷积网络 (Convolutional Network), 也叫卷积神经网络 (Convolutional Neural Network, CNN), 是一种具有局部连接、权重共享等特性的深层前馈神经网络, 专门用来处理具有类似网格结构的数据的神经网络。

1962 年, Hubel 和 Wiesel 通过对猫脑视觉皮层的研究, 首次提出了一种新的概念——“感受野” (Receptive Field), 对后来人工智能网络的发展起了很大的推动作用^[16]。感受野是受生物学上感受野的机制而提出, 在生物学上描述的是神经系统的一些神经元的特性。而在人工神经网络中, 感受野指的是指的是卷积神经网络层输出的特征向量上的像素点对应的输入图像上的区域, 通俗地讲, 就是特征向量上的一个点对应的输入图像上的区域。1980 年, Fukushima^[17] 基于生物神经学的感受野理论提出了神经认知机和权重共享的卷积神经层, 这被视为卷积神经网络的雏形。1989 年, LeCun 将反向传播算法与权值共享的卷积神经层相结合, 发明了卷积神经网络, 并首次将卷积神经网络成功地应用到美国邮局的手写字符识别程序中^[18]。1998 年, LeCun 提出了经典卷积神经网络模型 LeNet-5, 该模型是第一个成功应用于图像数字识别的卷积神经网络^[19]。

2.3 卷积网络的特点

卷积运算通过三个重要的思想帮助改进深度学习系统: 稀疏交互 (Sparse Interactions)、参数共享 (Parameter Shareing) 和等变表示 (Equivariant Representations)。

稀疏交互的本质是对全连接的规避, 这是通过使核的大小远小于输入的大小来达到的。当处理一张图像时, 输入的图像可能包含几十万个像素点, 但是我们可以使用只有数十个像素点的卷积核来达到提取特征的目的。这意味着我们不仅可以存储更少的参数, 而且还大大减少了计算量, 提高了统计效率。稀疏交互的图形化表示如图 2-2 所示。

参数共享是指在一个模型的多个函数中使用相同的参数。在传统的神经网络中, 当计算一层的输出时, 权重矩阵的每一个元素只使用一次, 当它乘以输入的一个元素之后就再也用不到了。在卷积神经网络中, 核的每一个元素都作用在输入的每一个位置上。参数共享保证了我们只需要学习一个参数集合, 而不是每一个位置都需要学习一个新的集合。因此, 卷积在存储需求和统计效率方面极大地优于稠密矩阵的乘法运算。




图 2-2 稀疏交互

在处理图像数据时，卷积产生了一个二维映射来表明某些特征在输入中出现的位置。如果我们移动输入中的图像，它的表示也会在输出中移动同样的量，这种性质就叫做等变表示。对于卷积来说，参数共享的特殊形式使得神经网络层具有对平移等变的性质。如果一个函数满足输入改变，输出也以同样的方式改变这一性质，我们就说它是等变的。特别的，如果函数 $f(x)$ 与 $g(x)$ 满足 $f(g(x)) = g(f(x))$ ，我们就说 $f(x)$ 对于变换 g 具有等变性。对于卷积来说，如果令 g 是输入的任意平移函数，那么卷积函数对于 g 具有等变性。

2.4 卷积网络的结构

卷积网络一般由数个卷积层（Convolutional layer）、池化层（Pooling layer）、全连接层及输出层交叉堆叠而成，卷积层和池化层一般会取多个，采用卷积层和池化层交替堆叠的模式。卷积层可以并行地计算多个卷积产生一组线性输出，每一个线性激活响应将会通过一个非线性的激活函数，例如线性整流激活函数。然后使用池化层来进一步调整这一层的输出。最后添加 0.2 个全连接层以输出最终结果。目前，整个网络结构趋向于使用更小的卷积核（比如 11 和 33）以及更深的网络结构。此外，由于卷积的操作性越来越灵活，池化层的作用也变得越来越小，因此目前比较流行的卷积网络中池化层的比例也越来越低，趋向于全卷积网络。

3 基于卷积网络的小麦病害图像分类

3.1 本文卷积网络结构

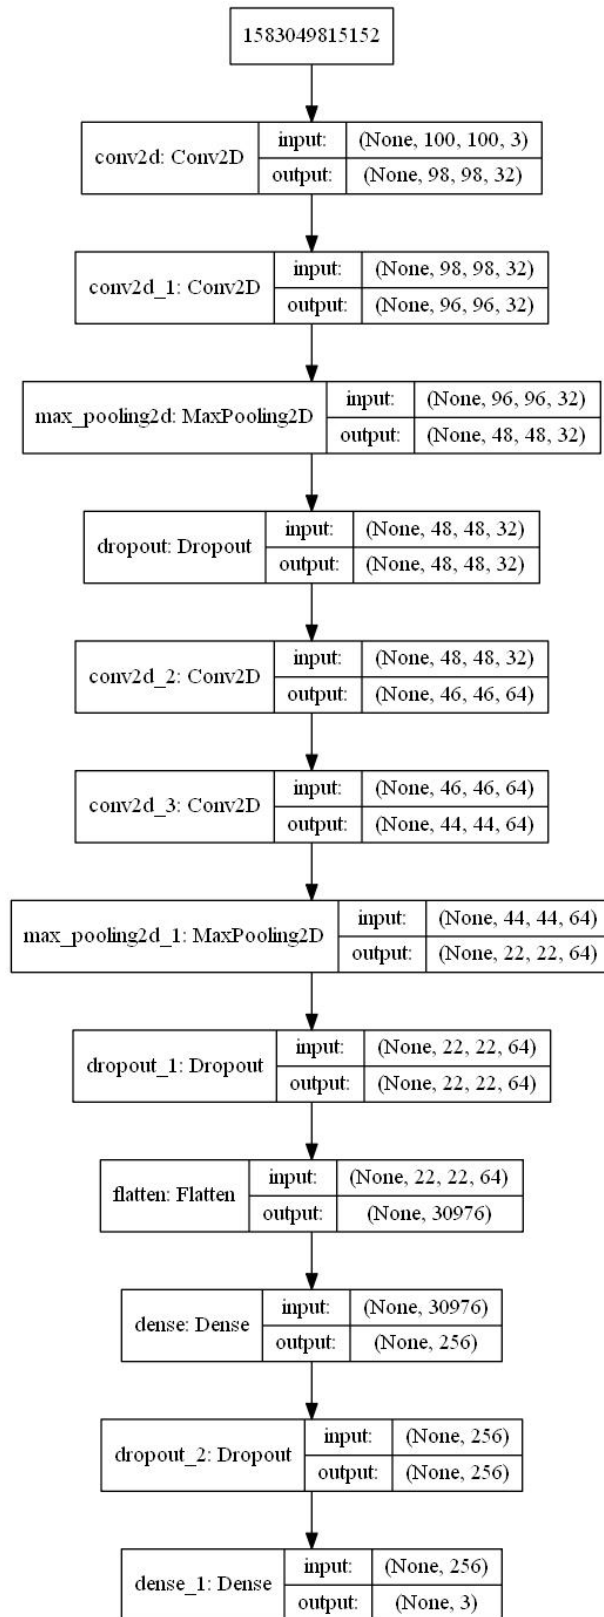


图 3-1 本文网络结构

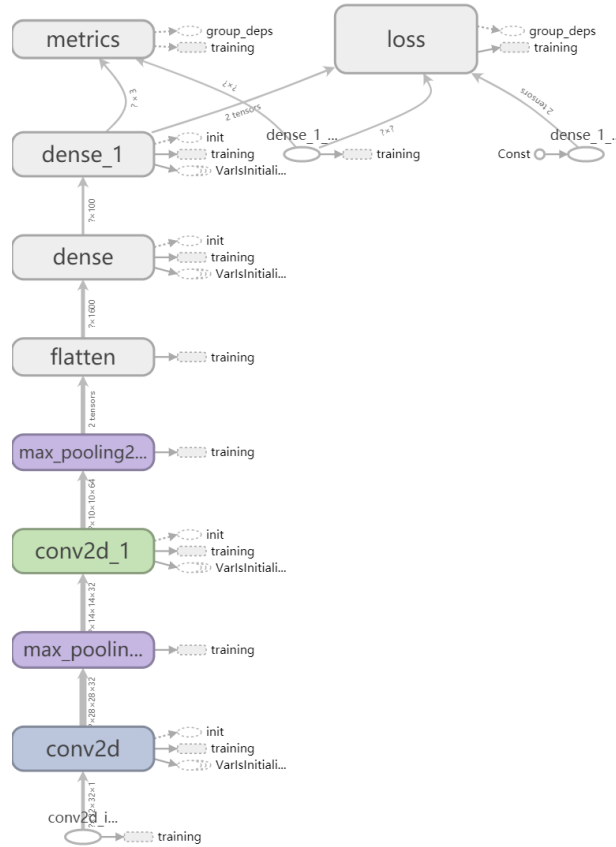


图 3-2 本文网络结构

本文卷积网络模型中每一层的输入输出由图 3-1所示，相对应网络层的操作由图 3-2所示。

第一层和第二层为卷积层，它们的过滤器大小均为 3×3 ，深度为 32，不使用全零填充，步长为 1。第一层接受的输入层大小为 $100 \times 100 \times 3$ ，所以输出的尺寸为 $100 + 3 - 1 = 98$ ，深度为 6。这一层共有 $3 \times 3 \times 1 \times 32 + 32 = 320$ 个参数，其中 32 个为偏置。下一层节点矩阵有 $98 \times 98 \times 32 = 307328$ 个节点，每个节点和 $3 \times 3 = 9$ 个当前层节点相连，所以本卷积层共有 $307328 \times (9 + 1) = 3073280$ 个连接。同理，第二层中共有 $96 \times 96 \times 32 \times (3 \times 3 + 1) = 2949120$ 个连接。

第三层为最大池化层，是一个 $96 \times 96 \times 32$ 的节点矩阵。在本层中使用的过滤器大小为 2×2 ，步长为 2。所以本层的输出大小为 $48 \times 48 \times 16$ 。

第四层为 Dropout 层，该层是 Hinton^[20] 为了防止过拟合、提高神经网络的性能而提出的。该层会随机丢弃一些神经元，dropout rate 为 0.25。

第五至八层结构与前四层相似，不过为了提取更深的特征，将深度增加为 64 层。

第九层 Flatten 操作将输入 $22 \times 22 \times 64$ 的张量展平为 1 维 1×30976 的张量，为下一层的全连接操作做准备。

第十层的全连接层 (Dense) 使用 ReLU (RecitifiedLinearUnit, ReLU) 作为激活函数。ReLU 即线性整流函数，指代数学中的斜坡函数： $f(x) = \max(0, x)$ ^[21]。该层输入大小为 30976，输出节点个数为 256 个，总共参数为 $30976 \times 256 + 256 = 7930112$ 个。

第十一层仍为 Dropout 层，随机丢弃率为 0.5。

第十二层为全连接层，该层使用 Softmax 函数作为激活函数，该函数能将一个含任意实数的 K 维向量 \mathbf{Z} “压缩”到另一个 K 维实向量 $\sigma(\mathbf{Z})$ 中，并使得每一个元素的值域均在 $(0, 1)$ 之间，并且所有原色的和为 1^[22]。该函数的形式通常由下式给出：

$$\sigma(\mathbf{Z})_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad \text{for } j = 1, \dots, K$$

该层输入大小为 256×1 的张量，输出大小为 3，即小麦病害类别个数。

3.2 LeNet-5 和 AlexNet 结构简介




图 3-3 LeNet-5 网络结构

LeNet-5 模型接受的输入层大小为 $32 \times 32 \times 1$ 。第一个卷积层过滤器尺寸为 5×5 ，深度与输出深度通为 6，步长为 1，输出尺寸为 $32 - 5 + 1 = 28$ 。该层共有 $5 \times 5 \times 1 \times 6 + 6 = 156$ 个参数，其中 6 个为偏置。下一层的节点矩阵有 $28 \times 28 \times 6 = 4704$ 个节点，每个节点和 $5 \times 5 = 25$ 个节点相连，所以本层共有 $4704 \times (25 + 1) = 122304$ 个连接。

第二至四层均为卷积核大小 2×2 、步长为 2 的卷积层。第五至七层均为全连接层，最后一层的输出为 10 个预测值。




图 3-4 AlexNet 网络结构

AlexNet 的输入图片大小为 $224 \times 224 \times 3$ ，第一个卷积层使用 96 个较大的卷积核 (11×11) 步长为 4；接着是 LRN 层；在之后是一个过滤器为 3×3 的最大池化层，步长为 2。接下来的卷积层中使用的卷积核都是 3×3 或 5×5 的大小，并且步长均为 1。最大池化层依然是 3×3 ，步长为 2。最后是三层均为全连接层，输出 1000 个预测结果。

3.3 实验步骤及操作

3.3.1 数据的获取及处理

实验所用的图片均来自网络。首先利用 Python 爬虫分别在百度图片和谷歌图片上爬取小麦的白粉病、叶枯病、锈病图片，保存至本地文件夹并做好备份。手工去除不清晰、含水印等劣质图片后，使用 Python 脚本将原始图片切割为多份 $300px \times 300px$ 的图片。然后将这些图片按 3:1:1 的比例随机分为 train、test、evaluate 三个数据集，使用 Python 将全部图片的尺寸缩小为 $100px \times 100px$ 后转为 numpy 数组，最后将这些数组序列化为 *.npy 文件，这样的做法为重复实验省去了磁盘 IO 和图片处理操作的时间。数据集的样本和比例分布如图 3-5 所示：




图 3-5 实验数据分布




图 3-6 数据样本

3.3.2 卷积网络模型的建立

在机器学习异常火热的今天，越来越多的机器学习库供大家学习。本文使用最受欢迎的深度学习框架 *TensorFlow* 搭建卷积网络模型，具体环境为：

- 操作系统：Windows 10 x64 Version 1809
- 处理器：Intel(R) Core(TM) i7-6700HQ CPU @ 2.60GHz
- 显卡：Geforce GTX 950M
- 软件环境：
 - Python 3.6.8 64-bit
 - tensorflow-gpu 1.12.0
 - keras 2.1.6-tf
 - tensorboard 1.12.1

在 *TensorFlow* 中已经集成了 *Keras*，它是使用 *Python* 编写的高级神经网络 API，能够以 *TensorFlow* 作为后端运行。实验中为快速搭建卷积网络，使用 *Keras* 可节省大量时间。以下即为核心代码：

```
model = Sequential()  
model.add(Conv2D(32, (3, 3), activation='relu', input_shape=(100, 100, 3)))  
model.add(Conv2D(32, (3, 3), activation='relu'))  
model.add(MaxPooling2D(pool_size=(2, 2)))
```



```
model.add(Dropout(0.25))
model.add(Conv2D(64, (3, 3), activation='relu'))
model.add(Conv2D(64, (3, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.25))
model.add(Flatten())
model.add(Dense(256, activation='relu'))
model.add(Dropout(0.5))
model.add(Dense(3, activation='softmax'))
sgd = SGD(lr=0.0001, decay=1e-6, momentum=0.01, nesterov=True)
model.compile(loss='categorical_crossentropy', optimizer=sgd, metrics=['accuracy'])
```

为了便于实验后的数据分析,需要在代码中加入回调函数 *keras.callbacks.TensorBoard*, 设置了必要的参数后, 程序在执行时便会在指定的文件夹写入运行过程的日志文件以供分析。

4 实验结果与分析

4.1 前期实验

不同于其他一些传统的黑盒机器学习方法，卷积网络所提取的图像特征在训练过程中是可视的，这不仅让人们对于卷积网络的工作过程有直观的了解，更能够帮助进行下一步的工作。

为了改进本文模型的性能，在实验初期进行了不同迭代次数（分别为 10000 次、20000 次）的实验，在图 4-1(a) 中以 [橙-深蓝]、[红-浅蓝] 图像对应其测试集和验证集的准确率；而 [粉-绿] 图像代表了卷积网络初步优化后的效果。验证准确率在 70%~75% 徘徊的原因来自于数据集：因为数据来自百度和谷歌图库，而这些图片是从各个网页上收集而来，其中大多数含有水印且画质模糊，为了收集到足够的实验用数据集，便在粗略挑选、裁剪后应用于实验，故此准确率不高。

第一次训练对应的是 [橙-深蓝] 图像。该图像是在初步建立卷积网络模型的情况下训练的，由于输入数据较为粗糙，准确率只有 65% 左右。由 4-1(b) 可以看出，在训练次数达到 1500 次时，验证损失率不降反升，这表明卷积网络模型存在过拟合的问题，而且在 [红-浅蓝] 图像中仍然存在该问题。[红-浅蓝] 图像是训练了 20000 次的结果，在只有数据集稍微改进的情况下，验证准确率提升到 72% 左右，但差别并不明显。

在一些深度学习图像分类训练中，有的直接将测试集用作验证集，这可能有混淆概念的嫌疑。在调整数据集比例（训练集:测试集:验证集=3:1:1）后，又将输入图像的大小从 $30 \times 30 \times 3$ 调整为 $100 \times 100 \times 3$ 之后，便有了第三次的图像。从 [粉-绿] 图像可以明显看出，这次训练中用不到一千次迭代便将验证准确率提升至 75%，而测试准确率不到两千次便达到了 99.84% 的准确率，远远好于前两次的训练效果。

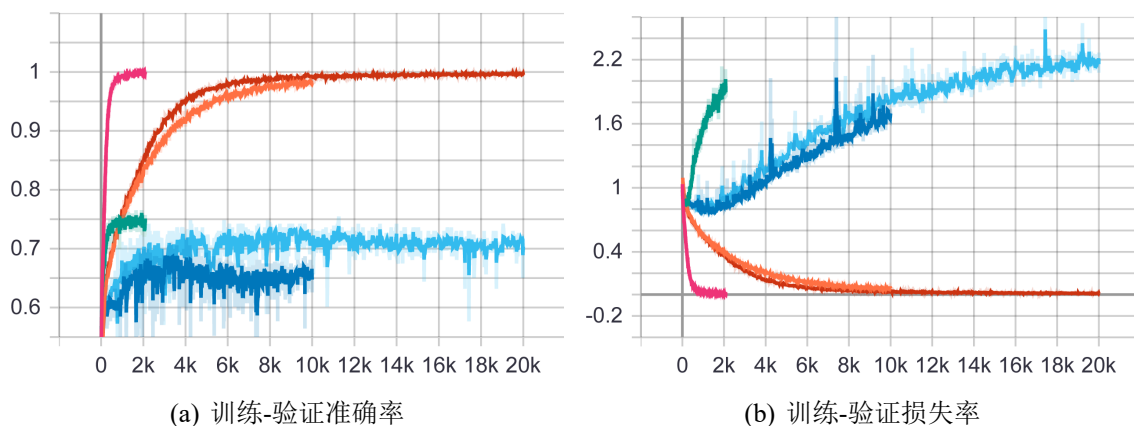


图 4-1 卷积核的翻转对特征提取的影响

4.2 参数优化

在初步实验后，我们可以在图 4-1 中看到，现有模型的验证准确率仅在 70% 左右徘徊，表现不尽人意。即使排除数据集的影响，也不能确说明该模型就是适合进行小麦病害

图像分类的模型。图 4-2是在原卷积网络模型的基础上以不同学习率训练 2000 次绘出的。该图中橙、蓝、红分别对应学习率为 10^{-3} 、 5×10^{-4} 、 10^{-4} 时的卷积网络模型。在模型表现方面，橙、蓝分别代表学习率为 10^{-3} 和 5×10^{-4} 的模型解决了学习率为 10^{-4} 时出现的过拟合问题；在准确率方面，二者表现相差不大，但是在损失率的比对中，的比对中，但是在损失率的比对中，学习率 5×10^{-4} 的模型表现更好。

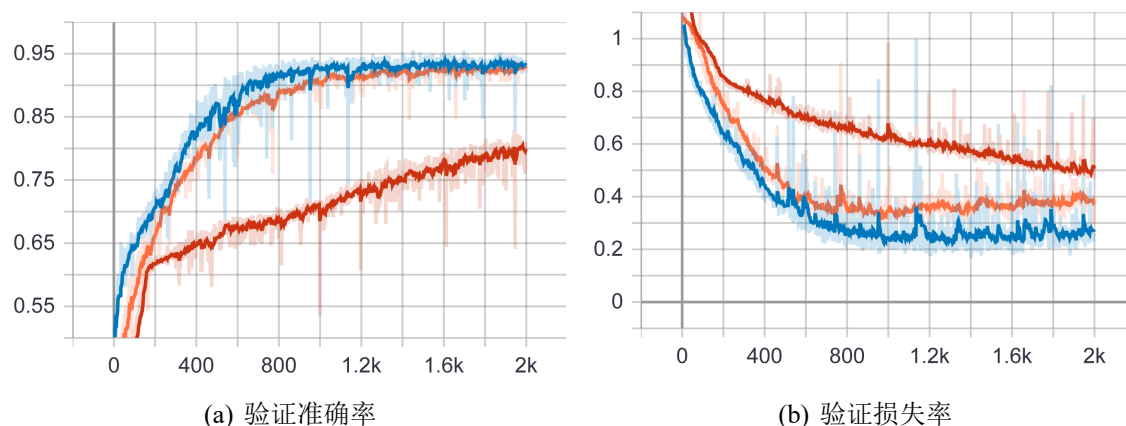


图 4-2 优化后准确率

4.3 模型性能对比

为了对比该模型在小麦病害图像分类的性能，在学习率 5×10^{-4} 的背景下将其与合适的模型进行对比实验。图 4-3中浅蓝代表 LeNet-5、深蓝代表本文模型。LeNet-5 运行次数较本文模型次数少的原因有二：第一，验证准确率在 400 次之后就趋于平缓，不再有明显增长；第二，在 200 次之后验证损失率不降反升，具有过拟合的缺点，再继续训练已无意义。

从分类模型的性能来看，LeNet-5 的验证准确率约为 84%~85%，本文模型约为 93%，稍高于 LeNet-5；从另一方面来讲，现今的 LeNet-5 模型具有过拟合的缺点，200 次训练后损失率不降反升。结合验证准确率和模型对比的结果，可以说本文提出的卷积网络模型更适用于处理小麦病害图像分类处理。




图 4-3 LeNet-5 与本文模型对比

4.4 分布图与直方图

图 4-4展示了 LeNet-5 训练 600 次和本文模型训练 2000 次的卷积层偏置变化分布图。从图中可以看出，前者的偏置变化出现放缓的迹象，这说明该模型的权重已经收敛，模型也越来越确定当前的偏置为最适合本模型的值。而对本文模型的偏置变化来看，它仍然需要更多的训练次数来得到更精确的权重及偏置。这也说明了训练层次深的模型需要更多的训练次数，也需要更大的开销。从另一方面来讲，本模型在参数优化方面做的不够好，仍有待进行调整。

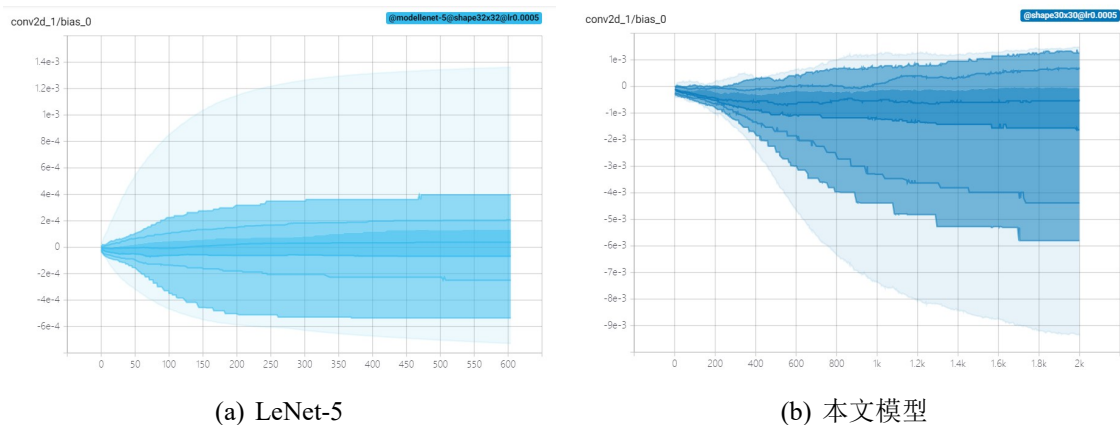


图 4-4 分布图

直方图和分布图是同样的数据在不同维度的表现，从 4-5 可以看到，LeNet-5 中的偏置自后向前逐渐减小，并在大约 400 次之后趋于平缓，不再有较大的变化，这意味着模型训练的完成。而就本文模型来看，偏置在训练快结束时仍有较小的变化趋势，这说明模型的训练并未完成。就图 2-2 来看，验证准确率和验证损失率均已收敛，不再有较大的变化，即使继续训练也不会有更多的收益，而在此时结束训练时更好的选择。

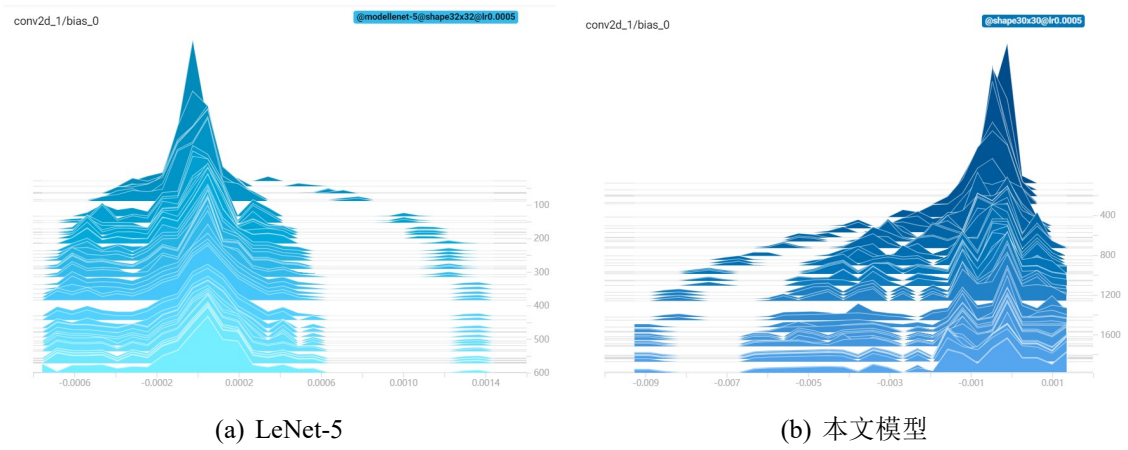


图 4-5 直方图

结论

本文提出了一种基于卷积神经网络的小麦病害图像分类方法。在建立卷积网络模型后，通过优化数据集、改进模型参数以减弱过拟合的影响等方面入手，经过多次实验得到了一个表现良好的小麦病害分类模型。将该模型与经典卷积网络模型 LeNet-5 等模型进行对比实验后，结果表明该模型具有更好的分类识别效果。

在本文实验中，受限于数据集的质量，导致参与实验的卷积网络模型不能很好地发挥其性能，而使得验证准确率并不能达到 99% 的理想状态。另一方面，本文模型一开始由过拟合的缺点，优化后虽然表现良好，但不能说明此时的模型最适合小麦病害图像分类，仍然有待优化模型参数以获得更好的效果。

参考文献

- [1] 中国作物种质信息网. 小麦病害[J/OL]. Website. <http://www.cgris.net/kp/小麦病害.htm>.
- [2] 林中琦. 基于卷积神经网络的小麦叶部病害图像识别研究[D]. 山东农业大学, 2018.
- [3] 王守志 [1, 何东健, 李文, 等. 基于核 K-均值聚类算法的植物叶部病害识别[J]. 农业机械学报, 2009, 40(3): 152-155.
- [4] 陈丽, 王兰英. 概率神经网络在玉米叶部病害识别中的应用[D]. , 2011.
- [5] 王树文, 张长利. 基于图像处理技术的黄瓜叶片病害识别诊断系统研究[D]. , 2012.
- [6] 张飞云. 基于量子神经网络和组合特征参数的玉米叶部病害识别[J]. 南方农业学报, 2013, 44(8): 1286-1290.
- [7] Tucker C C, Chakraborty S. Quantitative assessment of lesion characteristics and disease severity using digital image processing[J]. Journal of Phytopathology, 1997, 145(7): 273-278.
- [8] Sasaki Y, Okamoto T, IMOU K, et al. Automatic diagnosis of plant disease[J]. Journal of the Japanese Society of Agricultural Machinery, 1999, 61(2): 119-126.
- [9] Phadikar S, Sil J. Rice disease identification using pattern recognition techniques[C]//2008 11th International Conference on Computer and Information Technology. IEEE, 2008: 420-423.
- [10] Dubey S R, Jalal A S. Fruit disease recognition using improved sum and difference histogram from images[J]. International Journal of Applied Pattern Recognition, 2014, 1(2): 199-220.
- [11] Sladojevic S, Arsenovic M, Anderla A, et al. Deep neural networks based recognition of plant diseases by leaf image classification[J]. Computational intelligence and neuroscience, 2016, 2016.
- [12] Fuentes A, Yoon S, Kim S, et al. A robust deep-learning-based detector for real-time tomato plant diseases and pests recognition[J]. Sensors, 2017, 17(9): 2022.
- [13] McCulloch W S, Pitts W. A logical calculus of the ideas immanent in nervous activity[J]. The bulletin of mathematical biophysics, 1943, 5(4): 115-133.
- [14] Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20(3): 273-297.
- [15] 维基百科编者. 数字图像 [G/OL]. 维基百科, 2016(20161226)[2016-12-26]. <https://zh.wikipedia.org/w/index.php?title=数字图像&oldid=42568484>.
- [16] Hubel D H, Wiesel T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. The Journal of physiology, 1962, 160(1): 106-154.
- [17] Fukushima K, Miyake S. Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition[M]//Competition and cooperation in neural nets. Springer, Berlin, Heidelberg, 1982: 267-285.
- [18] LeCun Y, Boser B, Denker J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural computation, 1989, 1(4): 541-551.
- [19] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [20] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. arXiv preprint arXiv:1207.0580, 2012.
- [21] 维基百科编者. 线性整流函数 [G/OL]. 维基百科, 2019(20190418)[2019-04-18]. <https://zh.wikipedia.org/w/index.php?title=线性整流函数&oldid=54065566>.
- [22] 维基百科编者. Softmax 函数 [G/OL]. 维基百科, 2018(20180816)[2018-08-16]. <https://zh.wikipedia.org/w/index.php?title=Softmax函数&oldid=50894294>.

致谢

衷心感谢导师史春妹老师和理学院曲智林教授（老师）对本人的精心指导，他们的言传身教将使我终生受益。

感谢父母对我的关心和支持！感谢理学院老师和同学们对我的帮助！